

神经网络在金融预测中的可靠性评估： 一个基于模型稳定性的分析框架

林文灿^{1,2}, 洪永淼^{1,2}, 汪 畅¹, 魏云捷^{1,2}

(1. 中国科学院数学与系统科学研究院数学科学全国重点实验室, 北京 100190; 2. 中国科学院大学经济与
管理学院, 北京 100190)

摘 要 数据特性与模型结构间的匹配问题是制约神经网络在经济金融预测领域应用的关键因素。现有研究主要关注残差分析, 但在模型结构稳定性方面的探索相对有限。针对这一研究空白, 本文提出了一种基于神经网络参数分析的新研究范式, 用以量化和评估数据与模型的匹配程度。研究设计了一种基于网络参数的模型距离度量方法, 并建立了结合模型稳定性检验和残差检验的完整评估框架。基于外汇市场的实证研究结果表明, LSTM 模型的稳定性与回溯期长度之间存在显著的非线性关系。在多个评估维度中, 36 个月回溯期表现最优, 能够有效平衡短期波动与长期趋势的影响。本研究不仅为提升神经网络预测模型的可靠性提供了新的分析工具, 还进一步深化了机器学习方法在金融领域应用的理论基础。

关键词 神经网络参数; 结构稳定性; 残差检验; LSTM 回溯期; 汇率预测

Reliability Assessment of Neural Networks in Financial Forecasting: An Analytical Framework Based on Model Stability

LIN Wencan^{1,2}, HONG Yongmiao^{1,2}, WANG Chang¹, WEI Yunjie^{1,2}

(1. State Key Laboratory of Mathematical Sciences, Academy of Mathematics and Systems Science, Chinese Academy of Sciences, Beijing 100190, China; 2. School of Economics and Management, University of Chinese Academy of Sciences, Beijing 100190, China)

收稿日期: 2025-04-02

基金项目: 国家自然科学基金 (72171223, 71988101); 中国科学院青年创新促进会

Supported by National Natural Science Foundation of China (72171223, 71988101); Youth Innovation-Promotion Association of the Chinese Academy of Sciences

作者简介: 林文灿, 博士, 研究方向: 计量经济学, 时间序列分析, 模型平均, E-mail: linwencan@amss.ac.cn; 洪永淼, 世界计量经济学会会士, 发展中国家科学院院士, 中国科学院数学与系统科学研究院特聘研究员, 研究方向: 计量经济学, 时间序列分析, 金融计量学, 统计学, E-mail: ymhong@amss.ac.cn; 汪畅, 硕士, 研究方向: 机器学习, 人工智能, E-mail: 1500012779@pku.edu.cn; 通信作者: 魏云捷, 博士, 副研究员, 研究方向: 经济分析与预测, 国际贸易, E-mail: weiyunjie@amss.ac.cn.

Abstract The matching problem between data characteristics and model structures is a critical factor that constrains the application of neural networks in economic and financial forecasting. Existing studies primarily focus on residual analysis, while relatively little attention has been paid to the exploration of model structure stability. To address this research gap, this study proposes a novel research paradigm based on neural network parameter analysis to quantify and evaluate the degree of matching between data and models. A model distance measurement method based on network parameters is designed, and a comprehensive evaluation framework combining model stability testing and residual analysis is established. Empirical results from the foreign exchange market demonstrate a significant nonlinear relationship between the stability of the LSTM model and the length of the lookback period. Among multiple evaluation dimensions, a 36-month lookback period achieves the best performance, effectively balancing the impact of short-term fluctuations and long-term trends. This study not only provides new analytical tools to enhance the reliability of neural network forecasting models but also further deepens the theoretical foundation of machine learning methods in financial applications.

Keywords neural network parameters; structural stability; residual test; LSTM lookback period; exchange rate forecasting

1 引言

在大数据时代, 金融市场预测的主要挑战在于从复杂的数据环境中提取潜在的市场模式(周勇等, 2024). 传统计量经济学模型在处理非线性关系方面表现出明显的局限性(Gu et al., 2020; Favero, 2013; Xing et al., 2018; Kim et al., 2020). 针对这一问题, 神经网络技术凭借其处理非线性、高维特征和复杂动态关系的能力(Fischer and Krauss, 2018; Calvo-Pardo et al., 2021; Keane and Neal, 2020; Feuerriegel and Gordon, 2019; LeCun et al., 2015), 在股票收益率预测(李斌等, 2019; Oztekin et al., 2016)、高频交易(Ye et al., 2024)、风险管理(Lahmiri and Bekiros, 2019)、资产定价(Chen et al., 2024; 唐国豪等, 2024)和外汇市场波动性预测(Serpini et al., 2013)等金融领域得到了广泛应用. 然而, 神经网络的性能在很大程度上依赖于数据特性与模型结构的匹配程度. 这种匹配主要体现在两个方面: 一是数据分布是否符合模型假设, 二是模型是否能够捕捉数据中的逻辑关系(Zhang et al., 2021; Akbilgic et al., 2014; Ha et al., 2005; Bryson et al., 2021). 金融市场中普遍存在的非平稳性、结构性变迁和政策动态性, 可能导致训练样本期与预测期的数据分布存在显著差异, 从而对模型的预测稳定性产生不利影响(洪永淼和汪寿阳, 2024; Li et al., 2023; Inoue and Okimoto, 2022; Bech and Klee, 2011; Arjovsky et al., 2019; Wen et al., 2017). 数据分布与模型结构不匹配时, 过拟合或模型错误设定问题可能出现, 进而限制神经网络的实际应用效果(洪永淼和汪寿阳, 2021; 洪永淼, 2022; Cho et al., 2024; Zhou et al., 2022; Mao et al., 2023). 此外, 现有研究普遍缺乏系统的模型识别和充分性测试程序, 这不仅会加剧过拟合风险(Refenes and Holt, 2001), 还会阻碍对模型稳健性和可靠性的全面评估. 因此, 如何系统地评估深度学习模型与金融数据之间的匹配程度, 已成为一个亟待解决的关键性问题.

从计量经济学视角来看, 模型对数据特征的准确刻画应体现为残差具有白噪声特性, 即零均值、恒定方差和独立同分布 (Thomaidis and Dounias, 2011; 洪永淼, 2021). 基于这一理论基础, 研究者开始将传统计量经济学中的残差分析和模型错误设定检验引入神经网络模型评估领域. 例如, Refenes et al. (1997) 将条件协整理论应用于神经网络建模, 并展示了其在处理非平稳欧洲市场股指数据中的应用. Refenes and Holt (2001) 拓展了 Durbin-Watson (DW) 检验方法, 构建了适用于神经网络残差自相关性检验的框架, 并在隐含波动率预测中验证了其有效性. Blake and Kapetanios (2007) 利用神经网络拟合汇率时间序列的条件均值, 并通过残差的自回归条件异方差性 (autoregressive conditional heteroskedasticity, ARCH) 检验识别时间序列中的 ARCH 效应. 在股票回报预测研究中, Medeiros et al. (2006) 强调了序列平稳性和自相关性检验的重要性, 并提出将隐藏神经元个数的拉格朗日乘子 (lagrange multiplier, LM) 检验纳入模型错误设定检验框架. 基于此, Thomaidis and Dounias (2011) 和 Thomaidis and Dounias (2012) 进一步拓展了神经网络模型的诊断框架, 提出了适用于异方差和非正态分布场景的 LM 检验变体, 用于确定最优网络结构和评估模型适当性. 尽管这些残差检验方法在模型评估方面取得显著进展, 但其对数据分布稳定性的依赖以及对模型结构稳定性考虑的不足, 限制了其在复杂金融市场中的应用效果.

针对神经网络模型的稳定性问题, 现有研究更侧重于模型的外推稳定性, 而非网络内部结构的稳定性. 例如, Cheng et al. (2024) 通过构建基于互信息的多目标学习框架, 实现了机制模型与神经网络的协同训练, 有效增强了模型的外推能力. Zhang et al. (2024) 则创新性地将在计算机视觉领域的稳定学习方法迁移至神经网络回归领域, 提高了模型在非独立同分布数据集上的预测稳定性. 事实上, 统计学中的参数分析方法为研究神经网络内部结构稳定性提供了理想工具. 作为模型内部结构的核心组成部分, 神经网络的大量参数能够反映输入与输出之间的映射关系及训练过程中的动态调整机制, 从而帮助解释模型的行为 (Li et al., 2018; Montavon et al., 2018). 然而, 关于神经网络参数分析的现有研究主要集中在模型可视化和可解释性层面. 例如, Li et al. (2018) 利用多种可视化技术分析了神经网络结构对损失函数分布的影响, 并探讨了不同损失函数分布对模型可训练性和稳健性的作用. Montavon et al. (2018) 着重介绍了逐层相关传播 (layer-wise relevance propagation, LRP) 技术, 通过逐层分解网络权重等参数对预测结果的相关性, 捕捉参数的正负贡献以提升模型的可解释性. Kindermans et al. (2018) 则深入探讨了参数解释的本质, 认为参数主要反映对干扰的过滤而非信号方向, 并通过 PatternNet 和 PatternAttribution 方法优化了信号方向识别和相关性分解, 提升了模型解释能力.

据笔者所知, 目前鲜有研究利用模型参数对神经网络的结构稳定性以及模型与数据的匹配性进行系统性评估. 为填补这一研究空白, 本文提出了一套基于神经网络参数的完整数据-模型匹配评估框架, 旨在通过模型内部结构的刻画, 全面评估模型的稳定性及其与数据的匹配程度. 具体而言, 本文首先在理论层面定义了模型稳定性和数据匹配性的核心条件, 并提出基于神经网络参数矩阵 Frobenius 范数的归一化距离这一定义, 用于量化不同神经网络模型间的参数差异. 随后, 我们设计了基于模型间距离的统计检验方法, 包括网络参数稳定性分析和假设检验, 以验证神经网络在不同数据子集上的结构稳定性. 在此基础上, 本文进一步结合传统计量经济学中的残差分析方法, 对模型的预测残差进行系统性检验, 以确保模

型在多维度上的适配性. 在实证研究中, 本文以 1997–2021 年 6 种主要货币对的汇率月度数据为研究对象, 分别构建不同回溯期 (lookback period, lbp) 长度的长短期记忆网络 (long short-term memory, LSTM), 发现 36 个月的回溯期展现出最优的数据-模型匹配效果, 该结论得到了模型稳定性和残差检验的双重支持. 从经济意义看, 36 个月的时间窗口与金融市场的年度周期特征高度吻合, 能够有效捕捉宏观经济指标、企业财务报告和政策调整的周期性影响. 此外, 研究还发现不同货币对对回溯期的敏感度存在显著差异, 这种差异可能源于各国经济结构、政策框架和在全球金融体系中所扮演的角色的不同.

本文的主要贡献包括以下三个方面: 第一, 本文提出了一种基于神经网络参数矩阵 Frobenius 范数的归一化距离的度量方式, 为量化神经网络模型间的结构差异提供了新的工具, 该方法不仅考虑了参数间的直接差异, 还通过归一化处理提高了跨模型比较的可靠性; 第二, 本文建立了包含模型稳定性检验和残差分析的完整数据-模型匹配评估框架, 弥补了现有研究中对模型内部结构分析和数据分布适配性评估的不足; 第三, 本文通过系统性比较不同回溯期长度下 LSTM 模型的汇率预测表现, 发现 36 个月回溯期在捕捉短期波动与长期趋势平衡方面的显著优势, 并揭示了不同货币对在回溯期选择上的差异性, 为神经网络在金融预测中的应用提供了重要的方法论指导.

本文余下内容的结构安排如下: 第二节介绍循环神经网络和 LSTM 的结构与特点, 并定义神经网络模型的距离度量; 第三节提出数据-模型匹配的理论框架, 包括模型稳定性检验和残差分析; 第四节基于多种汇率数据评估框架的有效性, 分析 LSTM 不同回溯期长度的模型表现; 第五节总结研究发现, 并提出未来研究方向.

2 预备知识

2.1 循环神经网络与长短期记忆神经网络

循环神经网络 (recurrent neural networks, RNN) 是传统前馈人工神经网络的一种变体, 适用于处理时间序列数据或序列相关问题 (Williams and Zipser, 1989; Bengio et al., 1994; Schuster and Paliwal, 1997; Yu et al., 2019). 图 1 展示了 RNN 的基本结构, 除了输入层、隐藏层和输出层这几个传统前馈人工神经网络的基本组件, RNN 还有能够实现时序信息建模的多个时间步和循环结构, 从而形成信息的循环传递. 每个时间步的隐藏状态 $\mathbf{h}_t$ 由当前输入 $\mathbf{x}_t$ 和前一时间步的隐藏状态 $\mathbf{h}_{t-1}$ 共同决定, 可以表示为: 公式 (1),

$$\mathbf{h}_t = f(\mathbf{V}\mathbf{h}_{t-1} + \mathbf{U}\mathbf{x}_t + \mathbf{b}_h), \quad (1)$$

其中 $\mathbf{h}_t$ 表示 t 时刻的隐藏状态, $\mathbf{x}_t$ 表示输入序列在 t 时刻的值, $\mathbf{V}$ 为隐藏状态的权重矩阵, $\mathbf{U}$ 为输入层的权重矩阵, $\mathbf{b}_h$ 为偏置向量, f 为 $\tanh$ 或 ReLU 等激活函数. 输出的表达式为:

$$\mathbf{o}_t = g(\mathbf{W}\mathbf{h}_t + \mathbf{b}_y), \quad (2)$$

其中 $\mathbf{o}_t$ 表示输出序列在 t 时刻的值, $\mathbf{W}$ 为输出层的权重矩阵, $\mathbf{b}_y$ 为偏置向量, g 为激活函数. 理论上, RNN 的循环结构使其能够捕捉任意长序列数据中的时间依赖关系. 然而, 标准 RNN 在处理长序列时存在梯度消失或梯度爆炸问题 (Werbos, 1990; Williams and Zipser, 1995; Pearlmutter, 1995), 这限制了其在长期依赖时间序列数据建模中的应用.




图 1 循环神经网络结构图

为了解决这一问题, Hochreiter and Schmidhuber (1997) 提出了一种改进的网络架构——LSTM. 如图 2 所示, LSTM 的核心是其细胞状态 (cell state) 和三个门控单元:




图 2 LSTM 神经网络结构图

1) 输入门 (input gate), 用于控制新信息进入细胞状态的程度, 其数学表达式为:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i), \quad (3)$$

其中 i_t 为输入门的输出, $[h_{t-1}, x_t]$ 为前一时间步的隐藏状态和当前输入的级联向量, W_i 为输入门的权重矩阵, b_i 为输入门的偏置, σ 为激活函数.

2) 遗忘门 (forget gate), 用于控制历史信息保留在细胞状态中的程度, 其数学表达式为:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f), \quad (4)$$

其中 f_t 为遗忘门的输出, W_f 为遗忘门的权重矩阵, b_f 为遗忘门的偏置.

3) 输出门 (output gate), 用于控制细胞状态信息输出的程度, 其数学表达式为:

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o), \quad (5)$$

其中 $\mathbf{o}_t$ 为输出门的输出, $\mathbf{W}_o$ 为输出门的权重矩阵, $\mathbf{b}_o$ 为输出门的偏置.

这些门结构通过细胞状态和隐藏状态控制信息从一个 LSTM 单元传递到另一个 LSTM 单元, 使得网络能够有效捕获时间序列数据的长期依赖关系. 细胞状态存储的是网络的长期记忆, 其更新过程为

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \quad (6)$$

其中 $\odot$ 为 Hadamard (逐元素) 乘积运算符, $\mathbf{c}_t$ 为当前时间步的细胞状态, $\mathbf{c}_{t-1}$ 为前一时间步的细胞状态, 候选细胞状态 $\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c)$. 隐藏状态存储的是网络的短期记忆, 其更新过程为

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t), \quad (7)$$

其中 $\mathbf{h}_t$ 为当前时间步的隐藏状态.

值得注意的是, 回溯期是 LSTM 模型训练和预测中的关键超参数 (Fischer and Krauss, 2018; Kratzert et al., 2018; Saud and Shakya, 2020; Hashemi et al., 2022), 决定了模型利用到的历史信息长度. 回溯期的选择会显著影响模型性能, 过长的回溯期会增加模型复杂度和计算成本, 且可能导致模型对远期数据过于依赖而忽略近期信息, 过短的回溯期则可能无法捕获足够的历史信息.

2.2 神经网络参数与距离度量

在研究神经网络模型的稳定性时, 模型间的参数差异性是一个关键指标. 以 2.1 节的 LSTM 网络为例, 其网络参数为输入门、输出门、遗忘门的权重矩阵 $\mathbf{W}_i$, $\mathbf{W}_o$, $\mathbf{W}_f$ 和偏置 $\mathbf{b}_i$, $\mathbf{b}_o$, $\mathbf{b}_f$ 以及全连接层的权重矩阵 $\mathbf{W}_{fc}$ 与偏置 $\mathbf{b}_{fc}$. 不同回溯期长度的 LSTM 模型具有不同的网络参数矩阵. 为了量化网络参数的差异, 我们定义了基于神经网络参数矩阵 Frobenius 范数的归一化距离度量, 并设定距离 D 作为评价模型稳定性的量化指标.

定义 1 基于神经网络参数矩阵 Frobenius 范数的归一化距离

对于两个结构相同的神经网络模型 M_a 和 M_b , 其参数矩阵集合分别为 $\{\mathbf{W}\}_{M_a}$ 和 $\{\mathbf{W}\}_{M_b}$, 则 M_a 和 M_b 间基于 Frobenius 范数的归一化距离为:

$$D(\{\mathbf{W}\}_{M_a}, \{\mathbf{W}\}_{M_b})_{\text{norm}} = \frac{\sqrt{\sum_{t=1}^k \sum_{i=1}^{m(\mathbf{W}_t)} \sum_{j=1}^{n(\mathbf{W}_t)} (w_{tij}^a - w_{tij}^b)^2}}{\sqrt{\sum_{t=1}^k \sum_{i=1}^{m(\mathbf{W}_t)} \sum_{j=1}^{n(\mathbf{W}_t)} (w_{tij}^{\text{norm}})^2}}, \quad (8)$$

其中 k 是神经网络 M_a 和 M_b 的总层数, $m(\mathbf{W}_t)$ 和 $n(\mathbf{W}_t)$ 分别表示第 t 层神经网络参数矩阵的行数和列数, w_{tij}^a , w_{tij}^b 和 w_{tij}^{norm} 分别表示模型 M_a , M_b 和用于归一化的参考模型 M_{norm} 第 t 层神经网络参数矩阵 i 行 j 列的元素.

定义 1 提出一种基于神经网络参数矩阵 Frobenius 范数的归一化距离度量, 可以量化两个神经网络模型 M_a 和 M_b 之间的参数差异. 具体而言, 首先逐层计算 M_a 和 M_b 在每一层对应参数矩阵上的逐元素差值, 并利用这些差值计算 Frobenius 范数. 为消除参数规模对距离的影响, 使用参考模型 M_{norm} 的 Frobenius 范数作为归一化因子, 对距离进行标准化处理. 这一距离定义度量精确刻画了两个神经网络模型间参数的整体差异.

3 对数据-模型匹配问题的参数分析方法

3.1 数据-模型匹配条件

在预测建模中, 我们通常假定存在一个函数 F , 该函数依据输入的预测因子 $\mathbf{X}$ 来预测目标变量 $\mathbf{Y}$. 这一关系可以用以下一般化形式表达:

$$\mathbf{Y} = F(\mathbf{X}) + \epsilon, \quad (9)$$

其中 F 为预测模型的函数形式, ϵ 为随机误差项, 反映预测值与实际值之间的偏差. 为了确保预测模型的有效性和可靠性, 需要通过数据与模型的匹配性检验来验证模型在不同数据子集上均能保持稳定的结构和性能. 数据-模型匹配的条件可以归结为以下几点:

1) 模型稳定性. 模型稳定性是评估预测模型结构在不同数据子样本上保持一致性的能力. 具体而言, 在总体的不同子样本上, 利用相同的建模方法得到的 F 应保持稳定. 训练数据的不同采样 (例如通过交叉验证、分层抽样或滚动样本窗口) 不应显著影响预测函数 F 的形式或预测性能. 模型稳定性是确保泛化能力的基本条件. 若模型在不同子样本上表现出显著的结构差异或性能波动, 可能表明模型存在过拟合、变量遗漏或数据中存在异质性.

2) 模型无偏性. 无偏性假设在统计推断、经济解释和机器学习预测中均具有重要意义. 理想情况下, 残差 ϵ 应满足 $\mathbb{E}(\epsilon) = 0$, 以确保模型无系统性偏差. 这一条件意味着模型 F 能够捕捉 $\mathbf{Y}$ 与 $\mathbf{X}$ 的主要关系, 且误差项 ϵ 不包含任何系统性信息, 否则可能导致预测偏差.

3) 残差无自相关性. 残差的自相关性通常表明模型未能充分捕获数据中的动态特性 (如趋势、周期性或自回归结构等时间依赖性). 理想情况下, 残差项 ϵ 应该不存在自相关性, 即对于任意时间滞后 h , 残差的自相关函数 $\rho(h)$ 应满足 $\rho(h) = 0$. 如果残差存在自相关性, 可能导致参数估计的偏差和低效性、预测性能下降和统计检验的失效.

4) 残差正态性. 残差正态性是评估预测模型是否正确捕捉数据生成过程的重要条件之一. 理想情况下, 残差 ϵ 应满足正态分布假设, 即 $\epsilon \sim N(0, \sigma^2)$. 正态性假设在许多统计推断方法中起着核心作用, 例如线性回归中的参数显著性检验和置信区间估计. 虽然机器学习模型的性能通常不依赖于残差的分布形状, 但正态性检验仍可以帮助诊断模型是否正确捕捉了数据的潜在模式.

为了评估数据特性与模型结构的匹配程度, 首先应检验预测模型的结构稳定性. 在结构稳定的前提下, 再进一步检验模型的无偏性、残差无自相关性和正态性才具有实际意义. 这种分层次的检验策略可以细化数据与模型的匹配性评估, 帮助模型开发者发现潜在问题并进行有针对性的改进. 例如, 如果模型无法满足无偏性或残差无自相关性, 可能需要重新考虑变量选择、模型形式或数据预处理方式. 通过这种系统化的分析方法, 可以提高模型的预测能力和实际应用中的可靠性.

3.2 模型稳定性检验

在评估预测模型的可靠性时, 验证模型结构的稳定性是一个重要环节. 对于 LSTM 等神经网络模型, 模型稳定性要求在不同子样本上训练的模型, 其内部结构和网络参数应保持一致, 因为参数的变化直接决定了神经网络的输出表现.

模型稳定性的检验过程包括以下步骤:

1) 数据划分. 将样本数据划分为训练集 $\text{data}^{\text{train}}$ 和验证集 $\text{data}^{\text{valid}}$, 其中验证集 $\text{data}^{\text{valid}}$ 由独立的 k 个子集 $\text{data}_1^{\text{valid}}, \text{data}_2^{\text{valid}}, \dots, \text{data}_k^{\text{valid}}$ 组成.

2) 模型训练与验证. 以 $\text{data}^{\text{train}}$ 为训练集, $\text{data}_1^{\text{valid}}$ 为验证集, 训练一个固定结构的神经网络模型, 得到模型 M_1 ; 随后, 依次以 $\{\text{data}^{\text{train}}, \text{data}_1^{\text{valid}}, \dots, \text{data}_i^{\text{valid}}\}$ 为训练集, $\text{data}_{i+1}^{\text{valid}}$ 为验证集 ($1 \leq i \leq k-1$), 分别训练得到模型 $M_2, \dots, M_k$.

3) 参数稳定性分析. 通过计算模型间参数的距离 $D_2^1, \dots, D_k^1$, 比较模型 $M_2, \dots, M_k$ 与模型 M_1 在神经网络参数上的差异, 以量化参数的稳定性.

4) 统计假设检验. 对参数距离 $D_2^1, \dots, D_k^1$ 进行统计假设检验, 判断其是否满足模型稳定性要求.

通常, 对于大多数神经网络模型, 模型函数 F 通常被认为是 Lipschitz 函数或者一致连续函数. 这一特性允许通过分析神经网络参数的变化来严格检验模型的稳定性. 与传统的依赖于输出结果的过拟合检验相比, 这种基于模型间距离的检验方法更为严谨, 可以更准确地评估模型的稳定性, 从而为模型的最终部署提供坚实的科学依据.

3.2.1 模型间距离分布

为了进行统计检验, 首先需要明确距离 D 的分布特性. 我们利用第四节的实证数据生成 LSTM 模型的距离 D 样本 $\{D_k^1\}$, 其最优拟合分布为均值为 0.0365、标准差为 0.0117 的正态分布 $N(0.0365, 0.0117^2)$, 拟合结果如图 3 所示. 由于距离 D 具有非负性, 直接使用正态分布可能产生理论上的偏差. 因此, 我们对拟合结果中小于 0 的部分进行截断, 得到新的截断正态分布 $\hat{F}$. $\hat{F}$ 的概率密度函数为:

$$\hat{f}(x) = c \cdot \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}, \quad x \geq 0, \quad c = \frac{1}{1 - \Phi_{N(\mu, \sigma^2)}(0)}, \quad (10)$$




图 3 LSTM 神经网络归一化距离的先验分布 (a) 概率密度函数 (b) 累积分布函数

其中 $\mu = 0.0365$, $\sigma = 0.0117$, $\Phi_{N(\mu, \sigma^2)}$ 为未截断正态分布的累积分布函数, c 是归一化因子以保证概率密度函数的积分为 1.

接下来, 我们使用 Kolmogorov-Smirnov (KS) 检验 (Kolmogorov, 1933; Smirnov, 1948) 验证样本是否服从分布 $\hat{F}$, 结果如表 1 所示. 在 $\alpha = 0.05$ 的显著性水平下, 检验结果表明, LSTM 模型的距离样本分布服从截断正态分布 $\hat{F}$, 并通过了 KS 检验. 因此, 在后续的检验方法设计中, 可以合理假设距离 D 的先验分布为去除 $x < 0$ 部分的截断正态分布.

表 1 距离 D 先验分布 KS 检验结果表

	KS 统计量	p 值
基于 LSTM 神经网络参数矩阵 Frobenius 范数的归一化距离	0.0516	0.5938

3.2.2 模型间距离检验

为了评估预测模型的稳定性, 我们基于距离 D 设计了一种统计检验方法. 我们设定 $\mu_0 = 0.0365$ 作为模型稳定性的距离阈值, 提出以下假设检验: 原假设 H_0 为 $\mu \leq \mu_0$, 备择假设 H_1 为 $\mu > \mu_0$. 当原假设成立时, 模型间的差异被视为在可接受范围内, 模型具有稳定性. 当 $\mu = \mu_0$ 时, 距离 D 的截断正态分布的概率密度函数形式为:

$$f_D(x) = c \cdot \frac{e^{-\frac{(x-\mu_0)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}, \quad x \geq 0, \quad c = \frac{1}{1 - \Phi_{N(\mu_0, \sigma^2)}(0)}, \quad (11)$$

由 (11) 式, 可以求得 D 的期望 $\mathbb{E}(D)$ 与方差 σ_D^2 分别为:

$$\begin{aligned} \mathbb{E}(D) &= \int_0^{\infty} x f_D(x) dx \\ &= \frac{c\sigma e^{-\frac{\mu_0^2}{2\sigma^2}}}{\sqrt{2\pi}} + \mu_0, \end{aligned} \quad (12)$$

和

$$\begin{aligned} \sigma_D^2 &= \int_0^{\infty} x^2 f_D(x) dx - (\mathbb{E}(D))^2 \\ &= \frac{c\sigma^2}{\sqrt{2\pi}} \int_{-\frac{\mu_0}{\sigma}}^{+\infty} z^2 e^{-\frac{z^2}{2}} dz + \frac{2c\sigma\mu_0}{\sqrt{2\pi}} \int_{-\frac{\mu_0}{\sigma}}^{+\infty} z e^{-\frac{z^2}{2}} dz + \frac{c\mu_0^2}{\sqrt{2\pi}} \int_{-\frac{\mu_0}{\sigma}}^{+\infty} e^{-\frac{z^2}{2}} dz - (\mathbb{E}(D))^2 \\ &= \frac{c\sigma^2}{\sqrt{2\pi}} \int_{-\frac{\mu_0}{\sigma}}^{+\infty} z^2 e^{-\frac{z^2}{2}} dz + \frac{2c\sigma\mu_0}{\sqrt{2\pi}} e^{-\frac{\mu_0^2}{2\sigma^2}} + \mu_0^2 - (\mathbb{E}(D))^2. \end{aligned} \quad (13)$$

记样本均值为 $\bar{D} = \frac{\sum_{i=1}^n D_i}{n}$, 标准差为 $s = \sqrt{\frac{\sum_{i=1}^n (D_i - \bar{D})^2}{n-1}}$, 由 $\bar{D} \sim N(\mathbb{E}(D), \frac{\sigma_D^2}{n})$ 和 $\frac{(n-1)s^2}{\sigma_D^2} \sim \chi^2(n-1)$, 可得:

$$\frac{\bar{D} - \mathbb{E}(D)}{\frac{\sigma_D}{\sqrt{n}}} \sim N(0, 1), \quad (14)$$

和

$$\frac{\bar{D} - \mathbb{E}(D)}{\frac{s}{\sqrt{n}}} \sim t(n-1). \quad (15)$$

将 s 作为对 σ_D 的估计值, 根据式 (12) 和式 (13), 可以求出 $\mathbb{E}(D)$ 的实际值. 随后, 我们构造检验统计量 $t^* = \frac{\bar{D} - \mathbb{E}(D)}{\frac{s}{\sqrt{n}}}$. 若 $t^* > t_{\alpha, n-1}$ ($t_{\alpha, n-1}$ 为 t -分布的临界值), 则在 $\alpha = 0.05$ 的显著性水平下拒绝原假设 H_0 , 认为模型间的距离 $D > \mu_0$, 模型不稳定; 否则, 不拒绝原假设, 认为模型间的距离 $D \leq \mu_0$, 模型稳定.

3.3 模型残差检验

在验证神经网络模型稳定性后, 下一步需要对模型残差 ϵ 进行检验. 残差 ϵ 的检验是衡量数据与模型匹配程度的关键环节. 理想情况下, 残差 ϵ 应满足期望 $E(\epsilon) = 0$ 、无自相关性和正态性等 3 个基本假设.

模型残差 ϵ 的检验流程包括以下步骤:

1) 残差计算. 对于通过稳定性检验的数据集 $\{\text{data}^{\text{train}}, \text{data}_1^{\text{valid}}\}$ 和模型 M_1 , 计算残差序列.

2) 无偏性检验. 利用单样本 t -检验等方法检验残差均值是否显著偏离零. 假设检验的原假设 H_0 为 $\mathbb{E}(\epsilon) = 0$, 备择假设 H_1 为 $\mathbb{E}(\epsilon) \neq 0$, 若 p 值小于显著性水平 α , 则说明模型可能存在系统性偏差.

3) 自相关性检验. 应用 DW 检验 (Durbin and Watson, 1950, 1951) 和 Ljung-Box (LB) 检验方法 (Ljung and Box, 1978) 验证残差的自相关性. DW 检验是计量经济学中检验残差的一阶自相关性的常用方法. 若 DW 统计量的值接近 2 表明残差不存在显著自相关性, 若显著偏离 2 则表明残差存在正自相关或负自相关. LB 检验则常用于检测残差的高阶自相关性, 原假设 H_0 为残差序列无自相关性, 备择假设 H_1 为残差序列存在相关性. LB 检验通过分析残差的自相关函数 (autocorrelation function, ACF) 在多个滞后阶数 h 上的显著性来判断残差是否存在时间依赖性. 若检验结果拒绝原假设 H_0 , 则模型可能未能充分捕捉数据中的动态特性.

4) 正态性检验. 使用 KS 检验评估残差序列是否符合正态分布假设. KS 检验是一种非参数检验方法, 通过比较残差的经验分布函数与理论分布函数之间的最大差异来判断残差是否来自正态分布. 原假设 H_0 为残差序列服从正态分布, 备择假设 H_1 为残差序列不服从正态分布. 若 p 值小于显著性水平 α , 则拒绝原假设 H_0 , 说明残差序列不满足正态性假设.

通过以上步骤, 我们能够全面评估模型残差的统计特性, 从而验证模型结构与数据特性的匹配程度.

4 实证结果

4.1 数据描述与模型设定

根据 Ren et al. (2021) 和 Kouwenberg et al. (2017), 本文选取了 1997 年 1 月至 2021 年 12 月澳大利亚、加拿大、日本、新西兰、瑞士、英国和美国的月度汇率数据. 基于文献中的经典汇率模型, 本文提取了 9 个外生变量, 具体变量及其设定总结于表 2. 模型池包括无覆盖

利率平价模型、货币模型、贸易差额模型、购买力平价模型、泰勒规则模型、风险分担模型、商品价格指数模型、石油价格模型和流动性模型 (Sarkissian, 2003; Benigno and Thoenissen, 2008; Chen and Rogoff, 2003; Chen et al., 2010; Bakshi and Panayotov, 2013). 其中, 面板 A 中的 6 种模型以宏观经济基本面作为解释变量, 面板 B 中的 3 种模型则侧重于金融市场因素. 有关这些模型的详细描述可参见 Kouwenberg et al. (2017). 所有数据均来源于 China Economic Information Exchange (CEIC) 和 Federal Reserve Economic Data (FRED) 宏观数据库.

表 2 宏观基本面与金融汇率模型

模型	变量	具体形式
面板 A. 基于宏观基本面的模型		
无抛补利率平价 (UIP)	利率差	$x_{t1} = i_t - i_t^*$
货币模型	货币和产出增长率	$x_{t2} = \frac{m_t^*}{m_t} \cdot \frac{GDP_t}{GDP_t^*}$
贸易平衡模型	贸易平衡	$x_{t3} = TB_t / GDP_t - TB_t^* / GDP_t^*$
购买力平价 (PPP)	通货膨胀率	$x_{t4} = \pi_t - \pi_t^*$
泰勒规则模型	产出缺口	$x_{t5} = og_t - og_t^*$
风险分担模型	消费增长	$x_{t6} = cg_t - cg_t^*$
面板 B. 基于金融因子的模型		
大宗商品价格	大宗商品价格指数	$z_{t1} = COM_t$
原油价格	原油价格指数	$z_{t2} = OIL_t$
流动性	TED 利差	$z_{t3} = TED_t$

注: 1) * 表示非美国国家的变量.

2) 利用 Chow-Lin 方法将年度数据 (产出缺口和消费增长) 转换为月度数据 (Chow and Lin, 1971).

在数据预处理中, 我们将数据划分为训练集和测试集. 初始训练集 $data^{train}$ 包括从 1997 年 1 月至 2014 年 12 月的数据, 而验证集由 2015 年至 2021 年的数据逐年划分, 共生成 7 个独立验证子集 $data_i^{valid}$ ($1 \leq i \leq 7$). 为提高模型训练效率并减小偏差, 所有数据均基于初始训练集 $data^{train}$ 进行 z-score 标准化处理, 即减去 $data^{train}$ 的均值并除以 $data^{train}$ 的标准差:

$$_data^{train} = \frac{data^{train} - \text{mean}(data^{train})}{\text{std}(data^{train})}, \quad _data_i^{valid} = \frac{data_i^{valid} - \text{mean}(data^{train})}{\text{std}(data^{train})},$$

其中 $_data^{train}$ 和 $_data_i^{valid}$ 分别是初始训练集 $data^{train}$ 和第 i 个初始验证集标准化处理后的结果.

在模型训练阶段, 本文选用多种回溯期 (12, 24, 36, 48, 60, 72) 的 LSTM 模型进行汇率预测. 这是因为汇率数据通常具有一定的长期和短期依赖特性, 选择多种回溯期有助于捕捉不同时间尺度下的特征. 由于数据样本数量有限, 选择单层 LSTM 网络以控制模型复杂度, 避免过拟合. 模型的隐藏单元数设置为 32, 用于捕捉时间序列中的长短期依赖特征. 优化器选择 Adam, 损失函数采用均方误差 (mean squared error, MSE), 并引入早停策略以提升训练效率并防止模型过拟合.

4.2 模型稳定性检验结果

表 3 的模型稳定性检验结果显示, 在 $\alpha = 0.05$ 的显著性水平下, 36 个实验组中有 28 个模型通过了稳定性检验. 模型的稳定性与回溯期长度和货币对特征存在显著关联, 不同回

表 3 LSTM 神经网络归一化距离及其模型稳定性检验结果

汇率	lbp	D_2^1	D_3^1	D_4^1	D_5^1	D_6^1	D_7^1	t 统计量	p 值
AUD/USD	12	0.0637	0.0442	0.0532	0.0545	0.0551	0.0566	4.7588	0.0025
	24	0.0424	0.0448	0.0420	0.0471	0.0489	0.0481	2.3700	0.0320
	36	0.0446	0.0416	0.0394	0.0434	0.0457	0.0462	1.8357	0.0629
	48	0.0453	0.0469	0.0401	0.0447	0.0452	0.0464	2.1738	0.0409
	60	0.0430	0.0441	0.0455	0.0469	0.0484	0.0485	2.5131	0.0268
	72	0.0411	0.0381	0.0371	0.0470	0.0487	0.0498	1.8748	0.0598
USD/CAD	12	0.0185	0.0271	0.0318	0.0345	0.0387	0.0452	-0.9741	0.8126
	24	0.0209	0.0253	0.0304	0.0313	0.0321	0.0361	-1.8598	0.9390
	36	0.0224	0.0289	0.0317	0.0322	0.0338	0.0351	-1.5247	0.9061
	48	0.0245	0.0340	0.0344	0.0352	0.0349	0.0411	-0.6682	0.7332
	60	0.0262	0.0384	0.0358	0.0372	0.0457	0.0448	0.3871	0.3573
	72	0.0228	0.0378	0.0364	0.0394	0.0436	0.0459	0.3006	0.3879
USD/JPY	12	0.0379	0.0419	0.0492	0.0508	0.0525	0.0569	3.1198	0.0131
	24	0.0383	0.0411	0.0380	0.0396	0.0402	0.0402	0.8069	0.2282
	36	0.0308	0.0373	0.0367	0.0376	0.0405	0.0391	0.1288	0.4513
	48	0.0313	0.0362	0.0354	0.0367	0.0362	0.0373	-0.2629	0.5984
	60	0.0350	0.0407	0.0360	0.0368	0.0374	0.0365	0.1533	0.4421
	72	0.0325	0.0393	0.0371	0.0383	0.0392	0.0389	0.2755	0.3970
NZD/USD	12	0.0252	0.0303	0.0292	0.0367	0.0423	0.0398	-0.7272	0.7502
	24	0.0193	0.0234	0.0260	0.0264	0.0287	0.0300	-2.7502	0.9798
	36	0.0189	0.0247	0.0241	0.0277	0.0260	0.0270	-2.8012	0.9810
	48	0.0237	0.0308	0.0254	0.0359	0.0274	0.0279	-1.5014	0.9032
	60	0.0194	0.0289	0.0303	0.0326	0.0294	0.0298	-1.8037	0.9344
	72	0.0173	0.0282	0.0301	0.0321	0.0375	0.0403	-1.4645	0.8985
USD/CHF	12	0.0162	0.0237	0.0321	0.0400	0.0339	0.0410	-1.4141	0.8918
	24	0.0134	0.0169	0.0236	0.0251	0.0235	0.0258	-3.9712	0.9947
	36	0.0124	0.0163	0.0200	0.0243	0.0222	0.0247	-4.3384	0.9963
	48	0.0126	0.0170	0.0197	0.0231	0.0225	0.0255	-4.3261	0.9962
	60	0.0204	0.0252	0.0291	0.0260	0.0332	0.0368	-2.1426	0.9575
	72	0.0112	0.0275	0.0324	0.0285	0.0365	0.0406	-1.8476	0.9380
GBP/USD	12	0.0431	0.0561	0.0685	0.0722	0.0809	0.0813	8.0180	0.0002
	24	0.0279	0.0347	0.0432	0.0477	0.0516	0.0519	1.6089	0.0843
	36	0.0341	0.0369	0.0401	0.0405	0.0484	0.0461	1.1836	0.1449
	48	0.0255	0.0304	0.0359	0.0387	0.0435	0.0448	-0.0026	0.5010
	60	0.0217	0.0339	0.0456	0.0505	0.0569	0.0586	2.0748	0.0463
	72	0.0228	0.0321	0.0470	0.0533	0.0585	0.0602	2.4121	0.0304

溯期的模型在距离稳定性方面表现出显著差异, 而不同货币对对回溯期选择的敏感性也因其对应经济体的特性而有所不同. 从回溯期的角度来看, 36 个月回溯期的模型在稳定性上表现最佳. 在该回溯期下, 6 种汇率对 (AUD/USD、USD/CAD、USD/JPY、NZD/USD、USD/CHF 和 GBP/USD) 均通过了稳定性检验. 这表明 36 个月的回溯期能够较好地捕捉汇率市场的中长期动态, 例如年度经济周期、货币政策传导效应和市场行为的调整过程. 此外, 24 个月、48 个月和 72 个月回溯期的模型表现也较好, 分别有 5 种汇率可以通过稳定性检验, 反映出中长期回溯期在平衡短期波动与长期趋势方面的优势. 相比之下, 12 个月回溯期的模型稳定性最差, 仅有 3 种汇率能够通过稳定性检验. 从图 4 也可以看出, 12 个月回溯期的模型归一化距离较大, 且波动更为剧烈, 说明短回溯期不足以捕捉市场的完整信息结构, 无法捕捉市场的中长期趋势, 导致模型的稳定性显著下降. 从货币对的视角分析, 不同汇率对在模型稳定性方面的表现差异显著. USD/CAD、NZD/USD 和 USD/CHF 的模型表现出对回溯期长度的低敏感性, 在所有回溯期下均通过了稳定性检验. 由表 3 和图 4 可知, USD/JPY 只有在 12 个月回溯期下不通过稳定性检验, 在其他回溯期下表现得极其接近与稳定. 相比之下, AUD/USD 和 GBP/USD 则表现出更高的回溯期敏感性, 分别仅在 36 个月和 72 个月, 以及 24 个月、36 个月和 48 个月回溯期下通过了稳定性检验. 从图 4 也可以看出, 这 2 种汇率的模型归一化距离显著高于其他汇率.




图 4 LSTM 神经网络距离图

4.3 模型残差检验结果

在通过稳定性检验的 28 个模型中, 本文对其残差 ϵ 进一步进行了无偏性、自相关性以及正态性检验, 表 4 提供了相关检验结果. 检验结果表明, 在 $\alpha = 0.05$ 的显著性水平下, 通

过稳定性检验的 28 个模型中, 有 10 个模型不能同时通过无偏性、自相关性以及正态性检验. 这表明, 尽管模型在结构稳定性方面表现良好, 不同回溯期和货币对的残差特性仍存在显著差异, 这种差异可能与各国经济结构、政策框架及其货币在全球金融体系中的定位密切相关 (Gourinchas et al., 2019; Morys, 2013; Devereux et al., 2004). 如 4.2 节所述, USD/CAD、NZD/USD 和 USD/CHF 的模型在所有回溯期下均通过了稳定性检验, 但其残差检验结果表现各异. 对于 USD/CAD, 仅 12 个月回溯期的模型未能通过 1~6 阶的 LB 检验, 而其他回溯期均通过了所有残差检验. USD/CAD 的动态稳定性可能得益于加拿大和美国之间的经济和政策协调性. 两国的贸易关系高度稳定, 加拿大出口的大宗商品 (如原油) 对美国市场的依赖性较强, 而两国货币政策的高度同步性进一步减少了汇率波动的不确定性. NZD/USD 的残差检验结果则表现出显著分化. 在较长回溯期 (48 个月、60 个月和 72 个月) 下, 该模型未能通过完整的 LB 检验, 且 48 个月回溯期的模型还未通过残差均值的单样本 t 检验, 说明模型可能存在系统性偏差. 这种分化可能与新西兰经济对国际乳制品市场的高度依赖有关, 其

表 4 残差无偏性、自相关性和正态性检验结果

汇率	lb	统计量	均值 t	DW	LB lag1	LB lag2	LB lag3	LB lag4	LB lag5	LB lag6	KS
AUD /USD	36	统计量	0.2944	2.0452	0.4489	3.4618	3.4812	3.4812	3.7730	3.8290	0.0479
		p 值	0.7688	—	0.5029	0.1771	0.3232	0.4807	0.5825	0.6998	0.7874
	72	统计量	0.7374	1.9641	0.0183	0.9826	2.3632	2.4289	6.8512	9.9856	0.0683
		p 值	0.4621	—	0.8924	0.6118	0.5005	0.6574	0.2319	0.1253	0.4952
USD /CAD	12	统计量	1.3690	2.2897	7.3957	8.6295	10.3778	11.6400	13.6206	13.6355	0.0835
		p 值	0.1725	—	0.0065	0.0134	0.0156	0.0202	0.0182	0.0340	0.1111
	24	统计量	0.5518	2.1243	1.8331	2.9266	4.1405	4.2116	4.5828	5.8251	0.0735
		p 值	0.5817	—	0.1758	0.2315	0.2467	0.3781	0.4689	0.4431	0.2412
	36	统计量	0.7713	1.8121	2.2117	2.2776	4.8021	5.0282	6.3314	6.3523	0.0746
		p 值	0.4415	—	0.1370	0.3202	0.1869	0.2844	0.2753	0.3849	0.2584
	48	统计量	0.7882	1.9477	0.0727	2.2307	2.4266	3.9560	4.2971	5.7000	0.0678
		p 值	0.4317	—	0.7874	0.3278	0.4887	0.4120	0.5075	0.4576	0.4082
	60	统计量	1.0436	1.9170	0.3600	0.3979	2.6986	2.8416	3.7905	4.0661	0.0748
		p 值	0.2983	—	0.5485	0.8196	0.4405	0.5847	0.5800	0.6677	0.3338
	72	统计量	0.6001	1.9967	0.0031	0.0194	0.3445	0.4657	0.4832	5.9719	0.0445
		p 值	0.5494	—	0.9554	0.9904	0.9514	0.9768	0.9927	0.4263	0.9272
USD /JPY	24	统计量	0.9925	2.1834	3.2332	11.6164	13.1672	13.2514	15.4307	15.4647	0.0800
		p 值	0.3222	—	0.0722	0.0030	0.0043	0.0101	0.0087	0.0169	0.1646
	36	统计量	0.3137	1.7533	0.6041	0.7179	0.7179	4.6587	4.8664	5.6404	0.0935
		p 值	0.7542	—	0.4370	0.6984	0.8690	0.3241	0.4324	0.4647	0.0819
	48	统计量	0.8640	1.7069	5.6439	5.6554	6.7966	7.6155	9.5691	13.3967	0.0889
		p 值	0.3888	—	0.0175	0.0591	0.0787	0.1067	0.0884	0.0372	0.1341
	60	统计量	1.0527	1.9265	0.1543	0.7366	1.1390	1.8933	1.9671	2.2605	0.1298
		p 值	0.2941	—	0.6945	0.6919	0.7677	0.7554	0.8537	0.8942	0.0097
	72	统计量	1.2474	1.7974	1.8542	7.1303	8.3334	9.9090	10.4863	11.8529	0.0700
		p 值	0.2143	—	0.1733	0.0283	0.0396	0.0420	0.0626	0.0653	0.4641

表 4 (续)

汇率	lb	p	均值 t	DW	LB lag1	LB lag2	LB lag3	LB lag4	LB lag5	LB lag6	KS
NZD /USD	12	统计量	1.7499	1.9252	0.1348	1.0580	1.3225	2.1609	8.1498	8.6881	0.0422
		p 值	0.0817	—	0.7135	0.5892	0.7238	0.7062	0.1482	0.1919	0.8473
	24	统计量	0.8566	2.0060	0.4569	0.5134	0.5475	0.6901	4.1250	4.4456	0.0555
		p 值	0.3927	—	0.4991	0.7736	0.9083	0.9525	0.5316	0.6166	0.5802
	36	统计量	0.0434	1.9425	0.2009	0.2276	0.2372	0.5174	0.6964	0.7731	0.0576
		p 值	0.9654	—	0.6540	0.8924	0.9714	0.9718	0.9832	0.9928	0.5716
	48	统计量	2.1134	2.0839	1.5780	3.7398	7.7602	12.6585	13.0244	14.3452	0.0898
		p 值	0.0361	—	0.2090	0.1541	0.0512	0.0131	0.0232	0.0260	0.1271
	60	统计量	1.4934	1.9673	0.0019	1.6064	3.1646	10.1916	10.4292	10.4395	0.0533
		p 值	0.1374	—	0.9656	0.4479	0.3669	0.0373	0.0639	0.1073	0.7491
	72	统计量	1.0178	2.0845	1.1073	9.5228	9.5988	13.9579	14.3489	14.3612	0.0569
		p 值	0.3105	—	0.2927	0.0086	0.0223	0.0074	0.0135	0.0259	0.7220
USD /CHF	12	统计量	2.3208	1.9392	0.0043	0.1071	7.2581	7.4808	8.0462	8.3261	0.1275
		p 值	0.0213	—	0.9476	0.9479	0.0641	0.1126	0.1537	0.2152	0.0025
	24	统计量	0.6312	1.8196	2.0801	2.0887	7.0394	7.0596	8.6388	8.8113	0.0718
		p 值	0.5287	—	0.1492	0.3519	0.0707	0.1328	0.1244	0.1845	0.2653
	36	统计量	0.4526	2.0969	0.9389	1.2580	2.6371	2.6529	2.8029	2.8671	0.0575
		p 值	0.6514	—	0.3326	0.5331	0.4510	0.6175	0.7303	0.8253	0.5743
	48	统计量	1.0180	2.0866	1.0035	6.2947	6.9364	8.2459	10.6515	11.2972	0.0557
		p 值	0.3102	—	0.3165	0.0430	0.0740	0.0830	0.0587	0.0796	0.6565
	60	统计量	1.1478	2.0416	0.2689	2.3589	2.5529	2.6457	2.7228	4.2012	0.0536
		p 值	0.2528	—	0.6041	0.3075	0.4658	0.6188	0.7426	0.6495	0.7448
	72	统计量	1.7944	1.8203	1.3460	2.1473	8.7823	8.7831	8.8147	8.8988	0.0919
		p 值	0.0749	—	0.2460	0.3418	0.0323	0.0668	0.1167	0.1794	0.1676
GBP /USD	24	统计量	0.3019	1.9413	0.1388	0.6732	1.1398	1.1758	1.7031	2.1123	0.0456
		p 值	0.7630	—	0.7095	0.7142	0.7675	0.8821	0.8885	0.9091	0.8057
	36	统计量	0.1044	1.8108	2.3556	4.0533	5.5957	5.7180	10.4987	10.8924	0.0502
		p 值	0.9170	—	0.1248	0.1318	0.1330	0.2212	0.0623	0.0918	0.7376
	48	统计量	0.2446	2.1099	0.9697	1.0343	9.5659	11.7195	14.7664	15.9795	0.0436
		p 值	0.8071	—	0.3247	0.5962	0.0226	0.0196	0.0114	0.0139	0.8952

注: 均值 t 表示残差均值的 t 检验, LB lag1~6 表示残差的 1~6 阶 LB 检验.

汇率波动受全球大宗商品价格变化驱动, 在较长回溯期下可能放大这种外部经济冲击的影响. 对于 USD/CHF, 12 个月回溯期模型未能通过无偏性和正态性检验, 而 48 个月和 72 个月回溯期模型在个别滞后阶的 LB 检验中表现不佳. 这种结果可能反映了瑞士法郎作为避险货币的特点, 其受到全球避险情绪的驱动, 而瑞士央行长期实施的负利率和外汇干预政策可能对短期和长期波动产生不同影响. USD/JPY 的结果显示, 仅 36 个月回溯期的模型通过了所有残差检验. 其余回溯期中, 24 个月、48 个月和 72 个月的模型在滞后阶数的 LB 检验中未能完全通过, 而 60 个月回溯期的模型未通过正态性检验. 日元作为避险货币, 其汇率波动对短

期市场情绪的敏感性较高,而日本央行长期宽松政策的累积效应可能在中长期内平滑了波动,从而影响模型的稳定性。AUD/USD 和 GBP/USD 通过稳定性检验的模型数较少,但它们大多都能通过完整的残差检验。AUD/USD 的 36 个月和 72 个月回溯期模型通过了所有残差检验,反映了其汇率波动在中长期内的规律性。GBP/USD 的 24 个月和 36 个月回溯期模型可以通过完整的残差检验,但回溯期为 48 个月的模型无法通过 LB 检验。

4.4 实证结果总结和原因分析

实证结果表明,36 个月回溯期的模型在捕捉多种汇率动态特征方面表现出显著优势。这一结论主要基于以下几个维度的证据:首先,从模型稳定性的角度来看,36 个月回溯期下,6 种主要汇率的模型 (AUD/USD、USD/CAD、USD/JPY、NZD/USD、USD/CHF 和 GBP/USD) 均通过了稳定性检验,表明这一回溯期能够较好地平衡短期波动与中长期趋势,具有较高的模型稳定性。相比之下,12 个月回溯期的模型仅有半数汇率对通过了稳定性检验,同时其归一化距离显著较大,反映出其对短期波动的敏感性,难以有效捕捉汇率市场的中长期动态。其余回溯期 (如 48 个月、60 个月和 72 个月) 的模型也无法保证所有汇率对均通过稳定性检验,表明其在平衡短期和长期动态方面存在一定局限性。其次,从残差统计特性来看,36 个月回溯期下,6 种汇率对应的模型残差序列满足无偏性、无自相关性和正态性检验,符合传统时间序列建模方法的标准。相比之下,12 个月和 48 个月回溯期下,分别只有 NZD/USD 和 USD/CAD 一种汇率的模型可以通过残差检验。在 60 个月和 72 个月这种长回溯期下,也分别只有 USD/CAD 和 USD/CHF、AUD/USD 和 USD/CAD 两种汇率的模型可以通过完整的残差检验。24 个月回溯期模型的残差检验表现是最接近 36 个月回溯期的,有 4 种汇率的模型可以通过残差检验。这表明,36 个月回溯期在模型稳定性和残差特性方面表现最佳。因此,在构建 LSTM 汇率预测模型时,可以优先考虑 36 个月的回溯期,对于特定货币可以根据该货币市场的制度框架、经济结构和全球角色的差异等特征来使用其他回溯期进行建模。

从经济学角度分析,36 个月回溯期的合理性可以从以下 3 个维度得到解释:

1) 数据发布周期。许多宏观经济指标 (如 GDP、通胀率和国际贸易数据) 具有固定的发布周期,这些周期决定了经济数据对汇率在时间尺度上的影响。虽然货币政策框架会持续监测高频数据,但长期评估和战略制定通常基于年度数据的总结和趋势分析。36 个月回溯期能够覆盖 3 个完整的年度周期,既捕捉了月度和季度指标的累积效应,又揭示了年度经济数据所反映的长期趋势和政策传导的初步影响。这使得 36 个月回溯期能够较好地适应汇率市场中长期趋势与短期波动交织的特性 (Stock and Watson, 1991)。

2) 市场制度特征。从市场制度环境来看,机构投资者的绩效评估周期、企业财务报告周期等行为模式通常具有明显的年度特征。这些制度性安排影响市场参与者的交易策略和风险管理方式,并通过流动性和价格发现过程作用于汇率市场。36 个月的回溯期能够覆盖年度特征下的制度性行为模式,同时涵盖短期政策效应和市场波动的交互作用,能够较完整地捕捉制度环境对市场行为的塑造作用 (Beaver, 1968; Bongini et al., 2002; Healy and Palepu, 2001)。

3) 信息积累过程。在形成预期和决策时,市场参与者需处理短期信息与长期信息的交织

效应. 在汇率市场中, 短期因素 (如利率决议、地缘政治冲突) 驱动了汇率的高频波动, 而长期因素 (如年度经济表现、经济结构变迁、长期资本流动) 则塑造了汇率基本面趋势. 36 个月回溯期为建模短期波动与长期趋势提供了合理时间框架, 既能捕捉短期市场情绪变化, 又能揭示长期经济基本面对汇率的渐进影响 (Andersen and Beier, 2005; Rosa, 2011; Froot and Ramadorai, 2005).

5 结论

本文基于神经网络参数分析法, 对神经网络预测中数据特性与模型结构间的匹配问题进行了研究. 在方法层面, 我们建立了系统的数据与模型间匹配程度的评估框架, 提出了基于网络参数的模型间距离度量方式和模型稳定性检验方法, 而不仅仅局限于对模型残差的统计分析. 通过对 1997–2021 年期间 6 种主要货币对的实证研究, 我们发现使用 LSTM 模型预测汇率时, 36 个月的回溯期展现出最优的数据-模型匹配效果, 该结论得到了模型稳定性和残差检验的双重支持.

这些发现不仅验证了我们提出的数据-模型匹配程度检验框架的可靠性, 也为神经网络在金融预测中的应用提供了重要参考. 在未来研究中, 可以结合研究者或从业人员对模型稳定性的实际需求, 探索其他距离度量方式对模型稳定性评估的影响. 例如, 在使用区间数据建模时可以基于 D_K 距离进行模型稳定性评估. 本文提出的分析框架可以扩展到股票、商品期货等其他金融时间序列预测领域, 也可以与经济学和机器学习领域的可解释性方法或工具相结合, 进一步提升金融预测的科学性和实用性.

参 考 文 献

- 洪永淼, (2021). 理解现代计量经济学 [J]. 计量经济学报, 1(2): 266–284.
- Hong Y M, (2021). Understanding Modern Econometrics[J]. China Journal of Econometrics, 1(2): 266–284.
- 洪永淼, (2022). 概率论与统计学在经济学中的应用 [J]. 计量经济学报, 2(1): 1–18.
- Hong Y M, (2022). Economic Applications of Probability and Statistics[J]. China Journal of Econometrics, 2(1): 1–18.
- 洪永淼, 汪寿阳, (2021). 大数据、机器学习与统计学: 挑战与机遇 [J]. 计量经济学报, 1(1): 17–35.
- Hong Y M, Wang S Y, (2021). Big Data, Machine Learning and Statistics: Challenges and Opportunities[J]. China Journal of Econometrics, 1(1): 17–35.
- 洪永淼, 汪寿阳, (2024). ChatGPT 与大模型将对经济学研究范式产生什么影响?[J]. 计量经济学报, 4(1): 1–25.
- Hong Y M, Wang S Y, (2024). How Will ChatGPT and Large Models Influence the Research Paradigm in Economics?[J]. China Journal of Econometrics, 4(1): 1–25.
- 李斌, 邵新月, 李玥阳, (2019). 机器学习驱动的基本面量化投资研究 [J]. 中国工业经济, 2(1): 1–18.
- Li B, Shao X Y, Li Y Y, (2019). Research on Machine Learning Driven Quantamental Investing[J]. China Industrial Economics, 2(1): 1–18.
- 唐国豪, 朱琳, 廖存非, 姜富伟, (2024). 基于自编码机器学习的资产定价研究——中国股票市场的金融大数据分析视角 [J]. 管理科学学报, 27(9): 82–97.

- Tang G H, Zhu L, Liao C F, Jiang F W, (2024). Asset Pricing Research Based on Autoencoder Machine Learning: A Financial Big Data Analysis Perspective of the Chinese Stock Market[J]. *Journal of Management Sciences in China*, 27(9): 82–97.
- 周勇, 雷博麟, 张澍一, (2024). 金融大数据迁移学习及其应用 [J]. *计量经济学报*, 4(5): 1236–1257.
- Zhou Y, Lei B L, Zhang S Y, (2024). Transfer Learning and Its Applications in Financial Big Data[J]. *China Journal of Econometrics*, 4(5): 1236–1257.
- Akbilgic O, Bozdogan H, Balaban M E, (2014). A Novel Hybrid RBF Neural Networks Model as a Forecaster[J]. *Statistics and Computing*, 24: 365–375.
- Andersen T M, Beier N C, (2005). International Transmission of Transitory and Persistent Monetary Shocks under Imperfect Information[J]. *Journal of International Economics*, 66(2): 485–507.
- Arjovsky M, Bottou L, Gulrajani I, Lopez-Paz D, (2019). Invariant Risk Minimization[R]. arXiv Preprint: 1907.02893.
- Bakshi G, Panayotov G, (2013). Predictability of Currency Carry Trades and Asset Pricing Implications[J]. *Journal of Financial Economics*, 110(1): 139–163.
- Beaver W H, (1968). The Information Content of Annual Earnings Announcements[J]. *Journal of Accounting Research*, 53(1–2): 67–92.
- Bech M L, Klee E, (2011). The Mechanics of a Graceful Exit: Interest on Reserves and Segmentation in the Federal Funds Market[J]. *Journal of Monetary Economics*, 58(5): 415–431.
- Bengio Y, Simard P, Frasconi P, (1994). Learning Long-Term Dependencies with Gradient Descent Is Difficult[J]. *IEEE Transactions on Neural Networks*, 5(2): 157–166.
- Benigno G, Thoenissen C, (2008). Consumption and Real Exchange Rates with Incomplete Markets and Non-Traded Goods[J]. *Journal of International Money and Finance*, 27(6): 926–948.
- Blake A P, Kapetanios G, (2007). Testing for ARCH in the Presence of Nonlinearity of Unknown Form in the Conditional Mean[J]. *Journal of Econometrics*, 137(2): 472–488.
- Bongini P, Laeven L, Majnoni G, (2002). How Good Is the Market at Assessing Bank Fragility? A Horse Race Between Different Indicators[J]. *Journal of Banking & Finance*, 26(5): 1011–1028.
- Bryson B, Kunze H, La Torre D, Liuzzi D, (2021). A Generalized Multiple Criteria Data-Fitting Model with Sparsity and Entropy with Application to Growth Forecasting[J]. *IEEE Transactions on Engineering Management*, 70(5): 1900–1911.
- Calvo-Pardo H, Mancini T, Olmo J, (2021). Granger Causality Detection in High-Dimensional Systems Using Feedforward Neural Networks[J]. *International Journal of Forecasting*, 37(2): 920–940.
- Chen Y C, Rogoff K, (2003). Commodity Currencies[J]. *Journal of International Economics*, 60(1): 133–160.
- Chen Y C, Rogoff K S, Rossi B, (2010). Can Exchange Rates Forecast Commodity Prices?[J]. *The Quarterly Journal of Economics*, 125(3): 1145–1194.
- Chen L, Pelger M, Zhu J, (2024). Deep Learning in Asset Pricing[J]. *Management Science*, 70(2): 714–750.
- Cheng Y, Li Y, Liu X, (2024). Mutual Information-Guided Multiobjective Learning Framework for Augmenting Incomplete Mechanism Models With Neural Networks[J]. *IEEE Transactions on Industrial Informatics*, 20(9): 10966–10976.
- Cho Y, Bae H, Shin S, Youn Y D, et al. (2024). Make Prompts Adaptable: Bayesian Modeling for Vision-Language Prompt Learning with Data-dependent Prior[C]// *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(10): 11552–11560.

- Chow G C, Lin A, (1971). Best Linear Unbiased Interpolation, Distribution, and Extrapolation of Time Series by Related Series[J]. *The Review of Economics and Statistics*, 53(4): 372–375.
- Devereux M B, Engel C, Storgaard P E, (2004). Endogenous Exchange Rate Pass-Through When Nominal Prices Are Set in Advance[J]. *Journal of International Economics*, 63(2): 263–291.
- Durbin J, Watson G S, (1950). Testing for Serial Correlation in Least Squares Regression I[J]. *Biometrika*, 37: 409–428.
- Durbin J, Watson G S, (1951). Testing for Serial Correlation in Least Squares Regression II[J]. *Biometrika*, 38: 159–178.
- Favero C A, (2013). Modelling and Forecasting Government Bond Spreads in the Euro Area: A GVAR Model[J]. *Journal of Econometrics*, 177(2): 343–356.
- Feuerriegel S, Gordon J, (2019). News-Based Forecasts of Macroeconomic Indicators: A Semantic Path Model for Interpretable Predictions[J]. *European Journal of Operational Research*, 272(1): 162–175.
- Fischer T, Krauss C, (2018). Deep Learning with Long Short-term Memory Networks for Financial Market Predictions[J]. *European Journal of Operational Research*, 270(2): 654–669.
- Froot K A, Ramadorai T, (2005). Currency Returns, Intrinsic Value, and Institutional-Investor Flows[J]. *The Journal of Finance*, 60(3): 1535–1566.
- Gourinchas P O, Rey H, Sauzet M, (2019). The International Monetary and Financial System[J]. *Annual Review of Economics*, 11(1): 859–893.
- Gu S, Kelly B, Xiu D, (2020). Empirical Asset Pricing via Machine Learning[J]. *The Review of Financial Studies*, 33(5): 2223–2273.
- Ha K, Cho S, MacLachlan D, (2005). Response Models Based on Bagging Neural Networks[J]. *Journal of Interactive Marketing*, 19(1): 17–30.
- Hashemi R, Brigode P, Garambois P A, Javelle P, (2022). How Can We Benefit from Regime Information to Make More Effective Use of Long Short-term Memory (LSTM) Runoff Models?[J]. *Hydrology and Earth System Sciences*, 26(22): 5793–5816.
- Healy P M, Palepu K G, (2001). Information Asymmetry, Corporate Disclosure, and the Capital Markets: A Review of the Empirical Disclosure Literature[J]. *Journal of Accounting and Economics*, 31(1–3): 405–440.
- Hochreiter S, Schmidhuber J, (1997). Long Short-Term Memory[J]. *Neural Computation*, 9(8): 1735–1780.
- Inoue T, Okimoto T, (2022). International Spillover Effects of Unconventional Monetary Policies of Major Central Banks[J]. *International Review of Financial Analysis*, 79: 101968.
- Keane M, Neal T, (2020). Comparing Deep Neural Network and Econometric Approaches to Predicting the Impact of Climate Change on Agricultural Yield[J]. *The Econometrics Journal*, 23(3): S59–S80.
- Kim A, Yang Y, Lessmann S, Ma T, Sung M C, et al. (2020). Can Deep Learning Predict Risky Retail Investors? A Case Study in Financial Risk Behavior Forecasting[J]. *European Journal of Operational Research*, 283(1): 217–234.
- Kindermans P J, Schütt K T, Alber M, Müller K R, Erhan D, et al. (2018). Learning How to Explain Neural Networks: PatternNet and PatternAttribution[C]// 6th International Conference on Learning Representations.
- Kolmogorov A, (1933). Sulla Determinazione Empirica di Una Legge di Distribuzione[J]. *Giornale Dell'istituto Italiano Degli Attuari*, 4: 83–91.

- Kouwenberg R, Markiewicz A, Verhoeks R, Zwinkels R C, (2017). Model Uncertainty and Exchange Rate Forecasting[J]. *Journal of Financial and Quantitative Analysis*, 52(1): 341–363.
- Kratzert F, Klotz D, Brenner C, Schulz K, Herrnegger M, (2018). Rainfall–runoff Modelling Using Long Short-Term Memory (Lstm) Networks[J]. *Hydrology and Earth System Sciences*, 22(11): 6005–6022.
- Lahmiri S, Bekiros S, (2019). Can Machine Learning Approaches Predict Corporate Bankruptcy? Evidence from a Qualitative Experimental Design[J]. *Quantitative Finance*, 19(9): 1569–1577.
- LeCun Y, Bengio Y, Hinton G, (2015). Deep Learning[J]. *Nature*, 521(7553): 436–444.
- Li H, Xu Z, Taylor G, Studer C, Goldstein T, (2018). Visualizing the Loss Landscape of Neural Nets[C]// *Proceedings of the 32nd International Conference on Neural Information Processing Systems*: 6391–6401.
- Li D, Zhang L, Li L, (2023). Forecasting Stock Volatility with Economic Policy Uncertainty: A Smooth Transition GARCH-MIDAS Model[J]. *International Review of Financial Analysis*, 88: 102708.
- Ljung G M, Box G E, (1978). On a Measure of Lack of Fit in Time Series Models[J]. *Biometrika*, 65(2): 297–303.
- Mao X, Chen Y, Zhu Y, Chen D, Su H, et al. (2023). COCO-O: A Benchmark for Object Detectors under Natural Distribution Shifts[C]// *Proceedings of the IEEE/CVF International Conference on Computer Vision*: 6339–6350.
- Medeiros M C, Teräsvirta T, Rech G, (2006). Building Neural Network Models for Time Series: A Statistical Approach[J]. *Journal of Forecasting*, 25(1): 49–75.
- Montavon G, Samek W, Müller K R, (2018). Methods for Interpreting and Understanding Deep Neural Networks[J]. *Digital Signal Processing*, 73: 1–15.
- Morys M, (2013). Discount Rate Policy under the Classical Gold Standard: Core versus Periphery (1870s–1914)[J]. *Explorations in Economic History*, 50(2): 205–226.
- Oztekin A, Kizilaslan R, Freund S, Iseri A, (2016). A Data Analytic Approach to Forecasting Daily Stock Returns in an Emerging Market[J]. *European Journal of Operational Research*, 253(3): 697–710.
- Pearlmutter B A, (1995). Gradient Calculations for Dynamic Recurrent Neural Networks: A Survey[J]. *IEEE Transactions on Neural Networks*, 6(5): 1212–1228.
- Refenes A P, Holt W T, (2001). Forecasting Volatility with Neural Regression: A Contribution to Model Adequacy[J]. *IEEE Transactions on Neural Networks*, 12(4): 850–864.
- Refenes A P, Burgess A N, Bentz Y, (1997). Neural Networks in Financial Engineering: A Study in Methodology[J]. *IEEE Transactions on Neural Networks*, 8(6): 1222–1267.
- Ren Y, Liang X, Wang Q, (2021). Short-Term Exchange Rate Forecasting: A Panel Combination Approach[J]. *Journal of International Financial Markets, Institutions and Money*, 73: 101367.
- Rosa C, (2011). The High-Frequency Response of Exchange Rates to Monetary Policy Actions and Statements[J]. *Journal of Banking & Finance*, 35(2): 478–489.
- Sarkissian S, (2003). Incomplete Consumption Risk Sharing and Currency Risk Premiums[J]. *The Review of Financial Studies*, 16(3): 983–1005.
- Saud A S, Shakya S, (2020). Analysis of Look Back Period for Stock Price Prediction with RNN Variants: A Case Study on Banking Sector of NEPSE[J]. *Procedia Computer Science*, 167: 788–798.
- Schuster M, Paliwal K K, (1997). Bidirectional Recurrent Neural Networks[J]. *IEEE Transactions on Signal Processing*, 45(11): 2673–2681.
- Sermpinis G, Theofilatos K, Karathanasopoulos A, Georgopoulos E F, Dunis C, (2013). Forecasting

- Foreign Exchange Rates with Adaptive Neural Networks Using Radial-Basis Functions and Particle Swarm Optimization[J]. *European Journal of Operational Research*, 225(3): 528–540.
- Smirnov N V, (1948). Table for Estimating the Goodness of Fit of Empirical Distributions[J]. *Annals of Mathematical Statistics*, 19: 279–281.
- Stock J H, Watson M W, (1991). A Probability Model of the Coincident Economic Indicators[M]// Lahiri K, Moore G H (eds.), *Leading Economic Indicators: New Approaches and Forecasting Records*. Cambridge: Cambridge University Press, 63–90.
- Thomaidis N S, Dounias G D, (2011). On Detecting the Optimal Structure of a Neural Network under Strong Statistical Features in Errors[J]. *Journal of Time Series Analysis*, 32(3): 204–222.
- Thomaidis N S, Dounias G D, (2012). A Comparison of Statistical Tests for the Adequacy of a Neural Network Regression Model[J]. *Quantitative Finance*, 12(3): 437–449.
- Wen L, Gao L, Li X, (2017). A New Deep Transfer Learning Based on Sparse Auto-encoder for Fault Diagnosis[J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 49(1): 136–144.
- Werbos P J, (1990). Backpropagation Through Time: What It Does and How to Do It[J]. *Proceedings of the IEEE*, 78(10): 1550–1560.
- Williams R J, Zipser D, (1989). A Learning Algorithm for Continually Running Fully Recurrent Neural Networks[J]. *Neural Computation*, 1(2): 270–280.
- Williams R J, Zipser D, (1995). Gradient-based Learning Algorithms for Recurrent Networks and Their Computational Complexity[M]// *Backpropagation: Theory, Architectures, and Applications*. USA: L. Erlbaum Associates Inc., 433–486.
- Xing F Z, Cambria E, Welsch R E, (2018). Natural Language Based Financial Forecasting: A Survey[J]. *Artificial Intelligence Review*, 50(1): 49–73.
- Ye W, Yang J, Chen P, (2024). Short-Term Stock Price Trend Prediction with Imaging High Frequency Limit Order Book Data[J]. *International Journal of Forecasting*, 40(3): 1189–1205.
- Yu Y, Si X, Hu C, Zhang J, (2019). A Review of Recurrent Neural Networks: LSTM Cells and Network Architectures[J]. *Neural Computation*, 31(7): 1235–1270.
- Zhang C, Bengio S, Hardt M, Recht B, Vinyals O, (2021). Understanding Deep Learning (Still) Requires Rethinking Generalization[J]. *Communications of the ACM*, 64(3): 107–115.
- Zhang Y, Hua Y, Zhang X, He J, Jia M, et al. (2024). Enhancing Stability and Interpretability in the Study of Strength Behavior for Coarse-grained Soils[J]. *Computers and Geotechnics*, 171: 106333.
- Zhou K, Yang J, Loy C C, Liu Z, (2022). Conditional Prompt Learning for Vision-Language Models[C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*: 16816–16825.